

Ollama Model Benchmark Results

Generated: 2026-04-08T11:14:15.921474 | Token idle timeout: 120s | Absolute timeout: 300s | ■ Red cell = timeout / error (999999)

① Total Time: Question → Complete (sec)

Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Q11	Q12	Q13	Q14	Q15	Q16	Q17	Q18	Q19	Q20	Q21	Q22	Q23	Q24	Q25
22.9	26.3	24.5	30.3	24.8	29.0	23.3	21.6	22.1	23.8	20.8	29.6	19.8	23.1	24.7	23.5	27.8	22.6	20.3	27.5	25.9	24.4	22.9
1.9	1.9	2.5	1.9	1.5	2.1	1.6	1.9	2.4	1.6	2.2	1.7	1.6	2.5	1.5	2.4	1.4	1.7	1.0	1.3	2.2	1.9	1.9
6.5	13.3	9.2	8.5	10.4	10.2	12.3	10.8	7.3	8.6	6.9	11.6	6.5	7.5	10.0	10.3	9.7	10.8	9.1	12.1	10.4	11.3	8.5
136.7	156.8	137.7	177.6	156.7	267.1	206.2	173.6	133.1	134.9	198.9	143.6	133.3	237.9	66.5	228.6	155.2	132.8	82.1	116.9	30.4	140.7	82.1
8.2	16.2	10.0	12.4	12.4	14.4	11.8	8.0	9.7	10.5	8.9	15.7	9.0	10.7	9.1	9.5	10.2	20.5	8.4	14.9	14.2	12.7	10.4
8.2	7.6	7.1	6.9	6.6	11.2	6.3	8.2	8.0	6.4	7.4	6.8	5.4	8.4	8.0	6.8	6.3	6.0	3.2	10.1	6.7	6.7	5.4

② TTFT: Question → First Token (sec)

Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Q11	Q12	Q13	Q14	Q15	Q16	Q17	Q18	Q19	Q20	Q21	Q22	Q23	Q24	Q25
7.4	11.5	10.2	18.1	8.7	11.1	8.5	8.3	8.0	10.8	6.3	10.8	9.2	8.2	9.3	9.7	10.6	9.4	6.8	10.4	9.7	9.8	8.5
0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
1.1	5.3	1.6	0.6	1.5	1.1	1.2	1.1	1.1	1.1	1.3	1.1	1.4	1.2	1.2	1.2	1.1	1.2	1.4	1.1	1.1	1.1	1.1
0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
2.1	0.1	0.1	0.1	0.1	2.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

③ Generation Time: First Token → Complete (sec)

Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Q11	Q12	Q13	Q14	Q15	Q16	Q17	Q18	Q19	Q20	Q21	Q22	Q23	Q24	Q25
15.4	14.8	14.2	12.1	16.1	17.8	14.8	13.3	14.1	12.9	14.5	18.9	10.7	14.9	15.4	13.8	17.2	13.1	13.4	17.1	16.1	14.6	10.4
1.8	1.8	2.3	1.8	1.4	2.0	1.6	1.9	2.3	1.5	2.1	1.6	1.5	2.4	1.4	2.4	1.3	1.6	0.9	1.2	2.1	1.7	1.1

Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Q11	Q12	Q13	Q14	Q15	Q16	Q17	Q18	Q19	Q20	Q21	Q22	Q23	Q24	Q25
6.4	13.2	9.1	8.4	10.2	10.1	12.2	10.7	7.2	8.5	6.8	11.5	6.4	7.3	9.9	10.2	9.5	10.7	9.0	12.0	10.3	11.2	8.9
135.6	151.5	136.0	177.0	155.2	266.0	205.0	172.5	132.1	133.8	197.6	142.5	131.9	236.8	65.2	227.3	154.0	131.6	80.7	115.9	29.3	139.6	80.1
8.1	16.1	9.9	12.3	12.3	14.3	11.7	7.9	9.6	10.4	8.8	15.6	8.9	10.6	9.0	9.4	10.1	20.4	8.3	14.8	14.1	12.6	10.5
6.2	7.5	7.0	6.8	6.5	9.1	6.2	8.1	7.9	6.3	7.3	6.7	5.3	8.3	8.0	6.7	6.2	5.9	3.1	10.0	6.6	6.6	5.1

Model Summary

Model	OK	Timeout	Error	Avg Time (s)
gemma4:31b	29	0	0	24.4
llama3.1:8b	29	0	0	2.2
qwen3-vl:30b	29	0	0	10.5
llama3.1:70b	29	0	0	157.3
qwen3:30b	29	0	0	12.0
deepseek-r1:8b	29	0	0	8.1